МГТУ им. Н. Э. Баумана, кафедра ИУ5 курс "Технологии машинного обучения"

Лабораторная работа №5 «Линейные модели, SVM и деревья решений»

ВЫПОЛНИЛ:

Ерохин И.А.

Группа: ИУ5-61Б

ПРОВЕРИЛ:

Гапанюк Ю.Е.

Цель лабораторной работы: изучение линейных моделей, SVM и деревьев решений.

Задание:

- 1. Выберите набор данных (датасет) для решения задачи классификации или регрессии.
- 2. В случае необходимости проведите удаление или заполнение пропусков и кодирование категориальных признаков.
- **3.** С использованием метода train_test_split разделите выборку на обучающую и тестовую.
- 4. Обучите следующие модели:
 - одну из линейных моделей;
 - SVM:
 - дерево решений.
- **5.** Оцените качество моделей с помощью двух подходящих для задачи метрик. Сравните качество полученных моделей.

Выполненная работа:

В данной работе модели будут строиться для решения задачи классификации. Загрузка и первичный анализ данных. Формирование DataFrame:

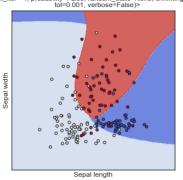
```
In [2]: wine = load_wine()
In [3]: # Cφορмируем DataFrame
        wine_df = pd.DataFrame(data= np.c_[wine['data'], wine['target']],
                             columns= list(wine['feature_names']) + ['target'])
In [4]: wine_df.isnull().sum()
Out[4]: alcohol
        malic_acid
        ash
        alcalinity_of_ash
        magnesium
        total_phenols
        flavanoids
        nonflavanoid_phenols
        proanthocyanins
        color_intensity
        hue
        od280/od315_of_diluted_wines
        proline
        target
        dtype: int64
In [5]: wine_df.head
                                        alcohol malic_acid ash alcalinity_of_ash magnesium total_phenols \
Out[5]: <bound method NDFrame.head of
                                           15.6 127.0
11.2 100.0
                      1.71 2.43
1.78 2.14
               13.20
                                                                                2.65
             13.16 2.36 2.67
14.37 1.95 2.50
13.24 2.59 2.87
                                                     18.6
                                                                101.0
                                                                                2.80
                                                    16.8
21.0
                                                                113.0
                                                                                3.85
                       5.65 2.45
3.91 2.48
4.28 2.26
2.59 2.37
        173 13.71
174 13.40
175 13.27
                                                    20.5
                                                                 95.0
                                                                                1.68
                                                                102.0
                                                                                1.80
                                                      20.0
                                                                120.0
                                                                                1.59
        176
              13.17
                                                      20.0
                                                                120.0
                                                                                1.65
```

Разделение данных на обучающую и тестовую выборки. Построение модели «Логистическая регрессия»:

```
In [6]: def convert_target_to_binary(array:np.ndarray, target:int) -> np.ndarray:
          # Если целевой признак совпадает с указанным, то 1 иначе
              res = [1 if x==target else 0 for x in array]
              return res
 In [7]: bin_wine_y = convert_target_to_binary(wine.target, 2)
 In [8]: wine_X_train, wine_X_test, wine_y_train, wine_y_test = train_test_split(
              wine.data, bin_wine_y, test_size=0.2, random_state=1)
 In [9]: cl1 = LogisticRegression()
In [10]: cl1.fit(wine X train, wine v train)
          onverge (status=1):
STOP: TOTAL NO. of ITERATIONS REACHED LIMIT.
          Increase the number of iterations (max_iter) or scale the data as shown in:
          https://scikit-learn.org/stable/modules/preprocessing.html Please also refer to the documentation for alternative solver options:
            https://scikit-learn.org/stable/modules/linear_model.html#logistic-regression
extra_warning_msg=_LOGISTIC_SOLVER_CONVERGENCE_MSG)
Out[10]: LogisticRegression(C=1.0, class_weight=None, dual=False, fit_intercept=True,
                              intercept_scaling=1, l1_ratio=None, max_iter=100,
multi_class='auto', n_jobs=None, penalty='l2',
random_state=None, solver='lbfgs', tol=0.0001, verbose=0,
                              warm_start=False)
In [11]: pred wine v test = cl1.predict(wine X test)
          pred_wine_y_test
In [12]: pred_wine_y_test_proba = cl1.predict_proba(wine_X_test)
          pred_wine_y_test_proba[:10]
Out[12]: array([[6.67502815e-02, 9.33249719e-01],
                  [9.99028518e-01, 9.71481719e-04],
                  [9.98580105e-01, 1.41989547e-03],
[9.99003483e-01, 9.96517066e-04],
                  [9.88929037e-01, 1.10709626e-02], [4.53547396e-02, 9.54645260e-01],
                  [9.54959671e-01, 4.50403288e-02],
                  [9.98955423e-01, 1.04457706e-03],
[7.08307657e-03, 9.92916923e-01],
                  [9.68840217e-01, 3.11597833e-02]])
In [13]: # Βεροяπность принадлежности κ θ κлассу [round(x, 4) for x in pred_wine_y_test_proba[:10,0]]
Out[13]: [0.0668, 0.999, 0.9986, 0.999, 0.9889, 0.0454, 0.955, 0.999, 0.0071, 0.9688]
In [14]: # Вероятность принадлежности к 1 классу
          [round(x, 4) for x in pred_wine_y_test_proba[:10,1]]
Out[14]: [0.9332, 0.001, 0.0014, 0.001, 0.0111, 0.9546, 0.045, 0.001, 0.9929, 0.0312]
In [15]: # Сумма вероятностей равна 1
          pred_wine_y_test_proba[:10,0] + pred_wine_y_test_proba[:10,1]
Out[15]: array([1., 1., 1., 1., 1., 1., 1., 1., 1.])
In [16]: accuracy_score(wine_y_test, pred_wine_y_test)
Out[16]: 0.97222222222222
```

Построение модели «SVC»:

```
def plot_contours(ax, clf, xx, yy, **params):
    """Plot the decision boundaries for a classifier.
                     ax: matplotlib axes object
                    clf: a classifier
xx: meshgrid ndarray
                    params: dictionary of params to pass to contourf, optional
                    Z = clf.predict(np.c_[xx.ravel(), yy.ravel()])
                    Z = Z.reshape(xx.shape)
#Можно проверить все ли метки классов предсказываются
                     #print(np.unique(Z))
                    out = ax.contourf(xx, yy, Z, **params)
                    return out
             def plot_cl(clf):
    title = clf._repr_
    clf.fit(wine_X, wine_y)
    fig, ax = plt.subplots(figsize=(5,5))
    X0, X1 = wine_X[:, 0], wine_X[:, 1]
                    xx, yy = make_meshgrid(X0, X1)
plot_contours(ax, clf, xx, yy, cmap=plt.cm.coolwarm, alpha=0.8)
ax.scatter(X0, X1, c=wine_y, cmap=plt.cm.coolwarm, s=20, edgecolors='k')
                    ax.set_xlim(xx.min(), xx.max())
ax.set_ylim(yy.min(), yy.max())
ax.set_xlabel('Sepal length')
ax.set_ylabel('Sepal width')
                     ax.set_xticks(())
                     ax.set_yticks(()
                     ax.set_title(title)
                    plt.show()
In [21]: wine_X_train, wine_X_test, wine_y_train, wine_y_test = train_test_split(
                      wine.data, wine.target, test_size=0.2, random_state=1)
In [22]: plot_cl(SVC(kernel='poly', degree=4, gamma=0.2, C=1.0))
                <bound method BaseEstimator.__repr__ of SVC(C=1.0, break_ties=False, cache_size=200, class_weight=None, coef0=0.0, decision_function_shape='ovr', degree=4, gamma=0.2, kernel='poly', max_iter=-1, probability=False, random_state=None, shrinking=True, tol=0.001, verbose=False)>
```

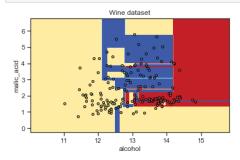


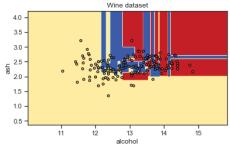
```
In [23]: svc = SVC(kernel='poly', degree=4, gamma=0.2, C=1.0).fit(wine_X_train, wine_y_train)
         target_svc = svc.predict(wine_X_test)
In [24]: accuracy_score(wine_y_test, target_svc)
Out[24]: 0.9444444444444444
```

Построение модели «Дерево решений»:

```
In [25]: def plot_tree_classification(title_param, ds):
            Построение деревьев и вывод графиков для заданного датасета
           n_classes = len(np.unique(ds.target))
            plot_colors = "ryb
           plot_step = 0.02
           # We only take the two corresponding features
              X = ds.data[:, pair]
y = ds.target
               clf = DecisionTreeClassifier(random_state=1).fit(X, y)
               plt.title(title_param)
```

In [26]: plot_tree_classification('Wine dataset', wine)





```
In [27]: wine_x_ds = pd.DataFrame(data=wine['data'], columns=wine['feature_names'])
wine_x_ds.head()
```

Out[27]:

	alcohol	malic_acid	ash	alcalinity_of_ash	magnesium	total_phenols	flavanoids	nonflavanoid_phenols	proanthocyanins	color_intensity	hue	od280/od31
0	14.23	1.71	2.43	15.6	127.0	2.80	3.06	0.28	2.29	5.64	1.04	
1	13.20	1.78	2.14	11.2	100.0	2.65	2.76	0.26	1.28	4.38	1.05	
2	13.16	2.36	2.67	18.6	101.0	2.80	3.24	0.30	2.81	5.68	1.03	
3	14.37	1.95	2.50	16.8	113.0	3.85	3.49	0.24	2.18	7.80	0.86	
4	13.24	2.59	2.87	21.0	118.0	2.80	2.69	0.39	1.82	4.32	1.04	
4												+

```
In [28]: # 06учим дерево на всех признаках wine
wine_tree_cl = DecisionTreeClassifier(random_state=1)
wine_tree_cl.fit(wine_x_ds, wine.target)
wine_tree_cl
```

```
In [29]: # Важность признаков
list(zip(wine_x_ds.columns.values, wine_tree_cl.feature_importances_))
```

```
In [30]: # Важность признаков в сумме дает единицу
sum(wine_tree_cl.feature_importances_)
Out[30]: 1.0
In [31]: from operator import itemgetter
               def draw_feature_importances(tree_model, X_dataset, figsize=(15,7)):
                     Вывод важности признаков в виде графика
                     # Сортировка значений важности признаков по убыванию
list_to_sort = list(zip(X_dataset.columns.values, tree_model.feature_importances_))
sorted_list = sorted(list_to_sort, key=itemgetter(1), reverse = True)
                     Sorteo_list = Sorteo(list_to_sort, key=:
# Ha3GaHUA npu3HAKOB
labels = [x for x,_ in sorted_list]
# BaжHOCMU npu3HAKOB
data = [x for _,x in sorted_list]
# Βυβοδ εραφυκα
fig, ax = plt.subplots(figsize=figsize)
ind _ no approx(loc(lobels))
                     ind = np.arange(len(labels))
plt.bar(ind, data)
                     plt.xticks(ind, labels, rotation='vertical')
                     # Вывод значений for a,b in zip(ind, data):
                           plt.text(a-0.05, b+0.01, str(round(b,3)))
                     plt.show()
return labels, data
In [32]: wine_tree_cl_fl, wine_tree_cl_fd = draw_feature_importances(wine_tree_cl, wine_x_ds)
                  0.35
                                                    0.312
                  0.30
                  0.25
                  0.20
                                                                  0.167
                  0.15
                  0.10
                                                                                0.058
                                                                                             0.053
                  0.05
                                                                                                           0.014
                                                                                                                        0.013
```

hue

In [33]: # Список признаков, отсортированный на основе важности, и значения важности

1315_of_diluted_wines

wine_tree_cl_fl, wine_tree_cl_fd

acid

alcohol

0.00

0.0, 0.0, 0.0, 0.0, 0.0, 0.0

ash

0.0

alcalinity_of_ash

0.0

phenols.

0.0

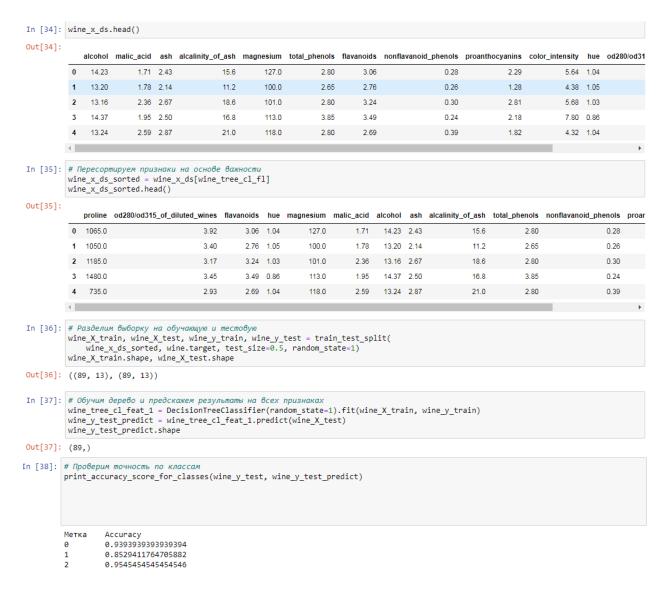
nonflavanoid_phenols

0.0

proanthocyanins

0.0

intensity



Как видно, результаты метрики Accuracy говорят о высоком качестве всех построенных моделей.